Proyecto Final del Curso de Inteligencia Artificial

Aplicación Multimodal con Deep Learning

Ing. Efrén Jiménez Delgado

Segundo Semestre 2026

1. Descripción general

El proyecto representa el **15 %** de la nota final y tiene una duración de **5 semanas**. Consiste en desarrollar una aplicación de *deep learning* que integre tres modalidades de entrada —**imágenes**, **video** y **audio**— para realizar tareas de clasificación y transcripción en tiempo casi real.

La aplicación debe ofrecer, en una sola interfaz:

1. clasificación de **imágenes** y de **video** (cuadro a cuadro) mediante *transfer learning*;
2. **transcripción de audio a texto** mediante un modelo entrenado con **CTC** (*Connectionist Temporal Classification*).

2. Objetivos de aprendizaje

Al finalizar el proyecto, cada estudiante será capaz de:

1. Aplicar modelos de *deep learning* a la clasificación en contextos multimodales.
2. Usar *transfer learning* y compararlo entre arquitecturas con conjuntos de datos limitados.
3. Entrenar y evaluar un modelo de reconocimiento de voz con CTC, usando como métrica la tasa de error de palabras (WER) o de caracteres (CER).
4. Integrar visión por computador y procesamiento de audio en una aplicación funcional.
5. Comunicar el trabajo en un artículo técnico con formato de conferencia.

3. Requisitos técnicos

3.1. Datos

Modalidad	Mínimo	Condiciones
Imágenes	200 imágenes etiquetadas	Al menos 2 clases; separación en entrenamiento / validación / prueba (p. ej. 70/15/15) sin fuga de datos entre particiones.
Audio	100 audios etiquetados con su transcripción	Frecuencia de muestreo y formato uniformes (p. ej. WAV mono, 16 kHz); transcripciones normalizadas; separación entrenamiento / validación.
Video	Al menos 1 video de prueba propio	Se usa para demostrar la clasificación sobre cuadros; no reemplaza el conjunto de imágenes.

Los conjuntos deben documentarse: fuente, licencia, procedimiento de etiquetado, número de ejemplos por clase y preprocesamiento aplicado. Si se usan datos propios con personas, se debe contar con su consentimiento.

3.2. Clasificación visual

- Usar **al menos dos modelos** preentrenados distintos (p. ej. ResNet, MobileNet, EfficientNet) y **compararlos** con la misma partición de datos.
- Reportar *accuracy*, matriz de confusión y precisión/*recall*/F1 por clase.
- Justificar la estrategia de *fine-tuning* (capas congeladas, tasa de aprendizaje, aumento de datos).
- Reportar el tiempo de inferencia por imagen (ms) en el equipo de la demostración.

3.3. Reconocimiento de voz con CTC

- Entrenar un modelo con pérdida CTC (por ejemplo, CNN + RNN al estilo DeepSpeech2) con **al menos 100 audios**.
- Evaluar con **WER y CER** en un conjunto de validación no visto durante el entrenamiento.
- Con tan pocos audios se esperan errores altos: se valorará el análisis (curvas de pérdida, ejemplos de aciertos y fallos) y el uso de aumento de datos o preentrenamiento si se justifica.

3.4. Aplicación integrada

- Una sola aplicación (por ejemplo, Streamlit, Gradio o una interfaz con OpenCV) que permita: cargar o capturar imagen, reproducir video clasificado cuadro a cuadro, y grabar o cargar audio y mostrar su transcripción.

- **Tiempo real** se entiende como una latencia que no interrumpa el uso: para video, al menos [5] cuadros por segundo; para audio, transcripción de fragmentos cortos en menos de [5] segundos. Se debe medir y reportar.
- Debe poder ejecutarse con instrucciones claras (`README` y archivo de dependencias).

4. Cronograma

Semana	Hito	Actividad
1	Propuesta	Tema, equipo, fuentes de datos y plan de trabajo.
2	Datos	Conjuntos de imágenes y audios listos, documentados y particionados.
3	Visión	Entrenamiento y comparación de los dos modelos de *transfer learning*.
4	Audio	Modelo CTC entrenado y evaluado (WER/CER).
5	Integración y entrega	Aplicación unificada, paper, código y presentación.

Fechas de entrega: propuesta [fecha]; entrega final [fecha]; presentación [fecha].

5. Entregables

1. **Aplicación funcional** que clasifique imágenes y video y transcriba audio, con demostración en vivo.
2. **Código fuente** documentado y organizado en un repositorio (con `README`, dependencias e instrucciones de ejecución).
3. **Conjuntos de datos** utilizados (mínimo 200 imágenes y 100 audios), preprocesados y con su documentación.
4. **Paper técnico** de [6 a 8] páginas en formato de dos columnas (plantilla IEEE o similar) con los apartados:
   - Resumen e introducción.
   - Marco teórico.
   - Metodología (datos, modelos, entrenamiento, aplicación).
   - Resultados y análisis (tablas, gráficos, comparación de modelos, WER/CER, latencia).
   - Conclusiones y trabajos futuros.
   - Referencias bibliográficas.
5. **Presentación** oral de [10] minutos más preguntas.

6. Evaluación

Criterio	Peso	Qué se valora
Visión: transfer learning (2 modelos)	20 %	Datos bien particionados, comparación justa, métricas por clase, análisis de errores.
Audio: modelo CTC (100 audios)	20 %	Entrenamiento correcto, WER/CER en validación, análisis de resultados.
Aplicación integrada	20 %	Funciona con las tres modalidades, latencia medida, facilidad de ejecución.
Calidad del código y reproducibilidad	20 %	Organización, documentación, semillas, dependencias, datos documentados.
Paper y presentación	20 %	Estructura, claridad, rigor, figuras y referencias.
Total	**100 %**	

Integridad académica

Todo código, dato o modelo ajeno debe citarse con su licencia. El uso de herramientas de IA generativa debe declararse en el paper; el equipo es responsable de comprender y poder explicar cada parte de su trabajo.

"La inteligencia artificial es la nueva electricidad" – Andrew Ng